Tóm tắt các bài báo nghiên cứu và mức độ liên quan đến dự án (VI)

COS40005 Computing Technology Project A · Trợ lý tri thức nội bộ VIB · Oct 31, 2026 · @Truong Ngoc Gia Hieu

Mười bài báo trong thư mục Research Paper của dự án đã được đọc toàn văn và tóm tắt dưới đây. Chỉ hai bài (Jeong & Lee 2025; Bhatt và cộng sự 2025) bàn về kiểm soát truy cập trong RAG, tức yêu cầu làm nên điểm khác biệt của dự án; các bài còn lại cung cấp nền tảng, hạ tầng và cách đánh giá.

1. Tổng quan

1.1 Phạm vi và phương pháp

Mỗi bài được đọc từ file PDF trong thư mục dự án. Với mỗi bài, phần tóm tắt ghi lại mục đích, phương pháp, dữ liệu và cách đánh giá, kết quả chính và hạn chế mà tác giả nêu, sau đó đánh giá mức liên quan đến Trợ lý tri thức nội bộ VIB (một Slack bot trả lời từ Confluence, có trích dẫn nguồn và truy xuất theo quyền). Các câu đánh dấu **suy luận** là cách đọc của nhóm, không phải khẳng định của bài báo.

1.2 Thang mức độ liên quan

- **Cao:** bài trực tiếp hỗ trợ một quyết định thiết kế hoặc kế hoạch đánh giá.
- **Trung bình:** bài cho nền tảng hoặc so sánh hữu ích, nhưng hệ thống hoặc lĩnh vực khác với dự án.
- **Thấp:** bài chỉ liên quan về chủ đề, có thể trích dẫn để đối chiếu.

1.3 Mười bài báo trong một bảng

#	Bài báo	Loại	Mức liên quan	Công dụng chính trong dự án
1	Lewis và cộng sự (2020)	Hội nghị (NeurIPS)	Cao	Định nghĩa RAG; truy xuất dày dựa trên chỉ mục gần đúng; thúc đẩy việc dẫn nguồn và cập nhật tri thức

#	Bài báo	Loại	Mức liên quan	Công dụng chính trong dự án
2	Gao và cộng sự (2024)	Bài tổng quan (arXiv)	Cao	Phân loại (RAG ngây thơ, nâng cao, mô-đun) và từ vựng đánh giá
3	Jeong & Lee (2025)	Tạp chí (IEEE Access)	Cao	Công trình gần nhất về RAG nhận biết quyền; đối chiếu với thiết kế lọc trước của nhóm
4	Bhatt và cộng sự (2025)	Bài quan điểm (arXiv)	Cao	Lập luận cho kiểm soát truy cập tất định; nguyên tắc người tham gia
5	Zhou và cộng sự (2025)	Bản thảo (arXiv)	Thấp	Phương án mã hóa thay cho lọc theo metadata, dùng để đối chiếu
6	Mukherjee và cộng sự (2025)	Bài công nghiệp (FSE 2025 Companion)	Trung bình	Trợ lý tài liệu doanh nghiệp có chuyên gia đánh giá
7	Es và cộng sự (2024)	Bài demo (EACL)	Cao	Chỉ số đánh giá RAG (độ trung thực, độ liên quan) cho Mục 8
8	Boonsri & Buranasaksee (2025)	Hội nghị (IEEE InCIT)	Trung bình	Kiến trúc phân lớp, bộ điều hợp, kiểm thử chấp nhận
9	Mohammed & Aref (n.d.)	Bài tổng quan	Thấp	Thuật ngữ (NLU, DM, NLG); danh sách thành phần
10	Malkov & Yashunin (2020)	Tạp chí (IEEE TPAMI)	Trung bình	Chỉ mục HNSW mà pgvector sử dụng (Lớp 4)

2. Nền tảng RAG

2.1 Lewis và cộng sự (2020): Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks

Khía cạnh	Tóm tắt
Trích dẫn	Lewis, P et al. 2020, NeurIPS 2020 (arXiv:2005.11401), Facebook AI Research, University College London và New York University
Mục đích và chủ đề	Mô hình ngôn ngữ lớn lưu kiến thức trong tham số, khó cập nhật và không chỉ ra được câu trả lời đến từ đâu. Bài báo giới thiệu retrieval-augmented generation (RAG), kết hợp một bộ sinh đã huấn luyện trước (bộ nhớ tham số) với một chỉ mục tài liệu có thể tìm kiếm (bộ nhớ phi tham số), và thử nghiệm trên các tác vụ đòi hỏi nhiều kiến thức.
Phương pháp	Bộ truy xuất: bi-encoder Dense Passage Retrieval (DPR) gồm hai bộ mã hóa BERT-base, chọn top-k bằng tìm kiếm tích vô hướng cực đại. Bộ sinh: BART-large (khoảng 400 triệu tham số), nhận câu hỏi ghép với từng đoạn được truy xuất. Hai biến thể: RAG-Sequence dùng cùng các đoạn cho toàn bộ câu trả lời, RAG-Token có thể dùng đoạn khác nhau cho từng token. Bộ mã hóa câu hỏi và bộ sinh được tinh chỉnh cùng nhau, còn bộ mã hóa tài liệu và chỉ mục được giữ cố định.
Dữ liệu và đánh giá	Nguồn tri thức: một bản Wikipedia (tháng 12/2018), cắt thành các đoạn 100 từ rời nhau, khoảng 21 triệu tài liệu, lập chỉ mục bằng FAISS với xấp xỉ Hierarchical Navigable Small World. Tác vụ: hỏi đáp miền mở (Natural Questions, TriviaQA, WebQuestions, CuratedTrec), hỏi đáp diễn giải (MS-MARCO), sinh câu hỏi Jeopardy và kiểm chứng sự thật (FEVER). Chỉ số: exact match cho hỏi đáp, ROUGE và BLEU cho sinh văn bản, độ chính xác nhãn cho FEVER, cùng đánh giá của con người về tính xác thực và tính cụ thể.

Khía cạnh	Tóm tắt
Kết quả chính	Đạt mức tốt nhất thời điểm đó trên hỏi đáp miền mở (RAG-Sequence: 44,5 trên Natural Questions, 56,8 trên TriviaQA, 45,2 trên WebQuestions, 52,2 trên CuratedTrec), không cần bộ xếp hạng lại hay bộ trích xuất riêng. Trong đánh giá của con người với sinh câu hỏi Jeopardy, RAG được cho là xác thực hơn BART ở 42,7% trường hợp so với 7,1% của BART, và cụ thể hơn ở 37,4% so với 16,8%. Các tác giả cũng cho thấy thay chỉ mục (Wikipedia 2016 so với 2018) cập nhật được tri thức của mô hình mà không cần huấn luyện lại.
Hạn chế	Bằng chứng đến từ Wikipedia và các bộ chuẩn công khai, không phải tài liệu nội bộ doanh nghiệp. Bài không thảo luận kiểm soát truy cập hay quyền theo từng người dùng (không được nhắc trong văn bản).
Mức liên quan đến dự án	**Cao.** Đây là nền móng của hệ thống: truy xuất trước, sinh sau, với chỉ mục có thể cập nhật. Bài hỗ trợ việc dự án dùng tìm kiếm vector dựa trên HNSW (Lớp 4) và lập luận rằng cập nhật tài liệu không cần huấn luyện lại. Thiết kế của nhóm khác ở hai điểm: dùng LLM đóng băng với việc bám nguồn ở mức prompt thay vì tinh chỉnh, và bổ sung lọc theo quyền mà bài không đề cập.

2.2 Gao và cộng sự (2024): Retrieval-Augmented Generation for Large Language Models: A Survey

Khía cạnh	Tóm tắt
Trích dẫn	Gao, Y et al. 2024, arXiv:2312.10997v5 (27/3/2024), Tongji University và Fudan University
Mục đích và chủ đề	Bài tổng quan có hệ thống về RAG cho mô hình ngôn ngữ lớn: lĩnh vực phát triển ra sao sau ChatGPT, các kỹ thuật chính và cách đánh giá hệ thống RAG.

Khía cạnh	Tóm tắt
Phương pháp	Khảo sát hơn 100 nghiên cứu về RAG. Phân các phương pháp thành ba mô hình và phân tích ba giai đoạn cốt lõi: truy xuất, sinh và tăng cường. Naive RAG gồm lập chỉ mục, truy xuất và sinh (mẫu "retrieve-read": làm sạch và cắt tài liệu, nhúng, lấy top-k đoạn, rồi sinh). Advanced RAG thêm tối ưu trước truy xuất (ví dụ viết lại câu hỏi) và sau truy xuất (ví dụ xếp hạng lại). Modular RAG xem các thành phần là mô-đun thay thế được với luồng linh hoạt.
Dữ liệu và đánh giá	Không có bộ dữ liệu mới. Bài liệt kê các tác vụ và bộ dữ liệu (ví dụ Natural Questions, TriviaQA, SQuAD, WebQuestions, PopQA, MS MARCO) và thực hành đánh giá: chỉ số truy xuất (Hit Rate, MRR, NDCG), ba điểm chất lượng (độ liên quan của ngữ cảnh, độ trung thực của câu trả lời, độ liên quan của câu trả lời) và bốn năng lực (chịu nhiễu, từ chối khi không có thông tin hay negative rejection, tích hợp thông tin, chịu thông tin sai). Bộ chuẩn: RGB, RECALL, CRUD; công cụ tự động: RAGAS, ARES, TruLens.
Kết quả chính	Một phân loại và một khung đánh giá, không phải kết quả thực nghiệm. Bài nêu các thách thức mở như RAG so với mô hình ngữ cảnh dài, độ bền vững và các vấn đề kỹ thuật gồm bảo mật dữ liệu.
Hạn chế	Là bài tổng quan nên không có thực nghiệm. Bảo mật chỉ được nhắc ngắn gọn như một thách thức kỹ thuật (ví dụ ngăn mô hình vô tình để lộ thông tin); kiểm soát truy cập không được phát triển.
Mức liên quan đến dự án	**Cao.** Dự án là một pipeline Naive RAG với hai bổ sung của Advanced RAG dự kiến cho bản Beta (bộ xếp hạng lại và bộ nhớ hội thoại). Thuật ngữ "negative rejection" mô tả đúng hành vi dự phòng mà dự án yêu cầu khi không có đoạn liên quan, và các điểm chất lượng của bài có thể dùng trực tiếp trong kế hoạch đánh giá.

3. Kiểm soát truy cập trong RAG

3.1 Jeong & Lee (2025): Permission-Aware RAG

Khía cạnh	Tóm tắt
Trích dẫn	Jeong, J & Lee, S-G 2025, IEEE Access, tập 13, tr. 192819-192835, doi:10.1109/ACCESS.2025.3628960, Seoul National University. Truy cập mở (CC BY 4.0), mã nguồn công khai trên GitHub.
Mục đích và chủ đề	Đa số nghiên cứu RAG giả định mọi người dùng đều được đọc mọi tài liệu được truy xuất, điều này không đúng trong doanh nghiệp, nơi dữ liệu nằm ở nhiều hệ thống với chính sách truy cập khác nhau. Bài đề xuất khung RAG nhận biết quyền, kiểm tra từng tài liệu được truy xuất với hệ thống quản lý danh tính và truy cập (IAM) của chủ dữ liệu theo thời gian thực, không gộp các chính sách thành một.
Phương pháp	Lúc lập chỉ mục: mỗi tài nguyên có resourceID riêng; các đoạn, vector nhúng và resourceID vào kho vector trung tâm, còn metadata IAM vào kho metadata. Lúc truy vấn: nhúng câu hỏi, lấy top-k tài liệu, sau đó Permission Retriever hỏi IAM của từng nhà cung cấp (GCP IAM, AWS IAM hoặc Keycloak) xem người dùng có được đọc từng tài liệu không, thông qua Credential Manager và IAM Adapter, rồi chỉ chuyển tài liệu được phép cho LLM. Mô hình mối đe dọa: Zero Trust, trong phạm vi là lộ thông tin và nâng quyền; giả mạo, can thiệp, phủ nhận và từ chối dịch vụ năm ngoài phạm vi.

Khía cạnh	Tóm tắt
Dữ liệu và đánh giá	Tập phát triển HotpotQA (thiết lập distractor): 13.783 tài liệu hỗ trợ và 7.405 câu hỏi nhiều bước. Nhúng: all-MiniLM-L6-v2 (384 chiều) trong kho FAISS; trả lời bằng gpt-4o-mini. Ba thí nghiệm: (1) theo kịch bản, 13 hồ sơ người dùng, mỗi hồ sơ 20 câu hỏi trên ba dịch vụ (Film trên GCP RBAC, Music trên AWS ABAC, People trên Keycloak RBAC), so với nhóm đối chứng gộp chính sách thành một vai trò; (2) quy mô lớn, 1.000 câu hỏi ngẫu nhiên, k=5, tám hồ sơ người dùng, đo chỉ số Permission Coverage so với exact match và F1; (3) độ trễ, thay đổi top-k và số worker đồng thời.
Kết quả chính	Nhóm đối chứng bị rò rỉ dữ liệu vì vai trò gộp bỏ mất điều kiện country=US, cho thấy rủi ro của việc gộp chính sách thủ công. Cách ủy quyền cho IAM thực thi đúng các quyết định cho phép và từ chối dự kiến. Chất lượng câu trả lời giảm khi độ phủ quyền giảm, bài định lượng sự đánh đổi giữa bảo mật và chất lượng. Độ trễ: tăng top-k từ 1 lên 20 thêm khoảng 140 ms độ trễ IAM, nhỏ so với thời gian suy luận của LLM; tăng worker từ 1 lên 15 giảm độ trễ IAM trung bình khoảng 70 phần trăm (từ 420,71 ms xuống 127,33 ms). Bộ nhớ đệm cho kiểm tra quyền được tắt khi đo.
Hạn chế	Phụ thuộc vào tính sẵn sàng của các dịch vụ IAM bên ngoài. HotpotQA (Wikipedia) không phản ánh quy mô hay độ phức tạp chính sách doanh nghiệp thật. Tác giả dự định thêm bộ nhớ đệm có TTL, kiểm tra sức khỏe và phương án dự phòng, cải thiện truy xuất khi độ phủ quyền thấp, và mã hóa vector nhúng cùng metadata.

Khía cạnh	Tóm tắt
Mức liên quan đến dự án	**Cao, và là bài gần nhất với đóng góp của nhóm.** Bài xác nhận vấn đề và sự cần thiết của việc cấp quyền theo từng người, theo thời gian thực. Thiết kế của nhóm khác ở một điểm quan trọng (**suy luận**): bài lọc sau khi lấy top-k, nên người có ít quyền có thể nhận ít hoặc không nhận được tài liệu dùng được, đây là lý do chất lượng câu trả lời giảm. Nhóm đặt bộ lọc quyền ngay trong truy vấn vector (không gian, phòng ban, mức truy cập không vượt quá bậc của người dùng), nên top-k chỉ được chọn từ văn bản được phép. Nhóm cũng dùng mô hình bậc đơn giản lưu trong một cơ sở dữ liệu thay vì gọi trực tiếp nhiều hệ IAM, phù hợp một nguồn Confluence nhưng sẽ không mở rộng được cho nhiều nguồn do các bên quản trị độc lập. Các chỉ số của bài (permission coverage, exact match, F1, độ trễ IAM) có thể tái sử dụng trong đánh giá của nhóm.

3.2 Bhatt và cộng sự (2025): Enterprise AI Must Enforce Participant-Aware Access Control

Khía cạnh	Tóm tắt
Trích dẫn	Bhatt, SS et al. 2025, arXiv:2509.14608 (bài quan điểm, bản thảo), Microsoft
Mục đích và chủ đề	Lập luận rằng mô hình tinh chỉnh và pipeline RAG trong doanh nghiệp có thể làm lộ dữ liệu mật cho người không có quyền, và các biện pháp phòng vệ xác suất (làm sạch prompt, lọc đầu ra, cô lập hệ thống, quyền riêng tư khi huấn luyện) không thể đảm bảo an toàn. Bài theo quan điểm rằng chỉ kiểm soát truy cập tất định, chi tiết, áp dụng khi tinh chỉnh và khi suy luận mới đáng tin cậy.

Khía cạnh	Tóm tắt
Phương pháp	Phân tích khái niệm và bảo mật chứ không phải thí nghiệm. Mục 2 minh họa các cuộc tấn công trích xuất dữ liệu lên mô hình tinh chỉnh. Mục 3 đề xuất tinh chỉnh có nhận biết kiểm soát truy cập: người dùng chỉ được dùng mô hình tinh chỉnh nếu có quyền với toàn bộ dữ liệu huấn luyện, và việc chọn dữ liệu và người dùng được mô hình hóa thành bài toán tìm biclique trong đồ thị hai phía. Mục 4 trình bày tấn công tiêm lệnh chéo (XPIA) vào trợ lý email dùng RAG, trong đó người gửi độc hại giấu chỉ dẫn để trợ lý lộ dữ liệu của người dùng khác, và giải thích vì sao các biện pháp hiện có thất bại. Sau đó bài nêu nguyên tắc: mọi nội dung dùng trong huấn luyện, truy xuất hay sinh phải được phép đối với tất cả người tham gia tương tác.
Dữ liệu và đánh giá	Không có bộ dữ liệu hay bộ chuẩn. Bằng chứng là các kịch bản tấn công và lập luận. Tác giả cho biết một giải pháp ban đầu đã được triển khai trong Microsoft Copilot Tuning.
Kết quả chính	Luận điểm trung tâm: cần kiểm soát truy cập tất định ở mọi giai đoạn, và việc người xem lại đầu ra không chặn được cuộc tấn công đã mô tả. Không có kết quả định lượng trong văn bản.
Hạn chế	Là bài quan điểm, không có đánh giá đo lường. Tác giả nêu các vấn đề mở: trọng số của tài liệu, kiểm tra quyền cho nhiều mô hình, ACL thay đổi theo thời gian và ACL cấu hình sai.
Mức liên quan đến dự án	**Cao.** Bài hỗ trợ nguyên tắc của dự án: quyền phải được thực thi trước khi LLM nhìn thấy văn bản, chứ không nhờ mô hình tự che thông tin. Bài cũng nêu một điểm nhóm cần xử lý (**suy luận**): trên Slack, câu trả lời của bot trong kênh hoặc luồng đọc được bởi mọi thành viên kênh, nên "được phép với mọi người tham gia" có nghĩa là câu trả lời không được vượt quá những gì các độc giả của kênh được xem, chứ không chỉ những gì người hỏi được xem. Điều này chưa được nêu trong thiết kế hiện tại và nên ghi là quyết định còn mở.

3.3 Zhou và cộng sự (2025): Privacy-Aware RAG: Secure and Isolated Knowledge Retrieval

Khía cạnh	Tóm tắt
Trích dẫn	Zhou, P, Feng, Y & Yang, Z 2025, arXiv:2503.15548, Beijing University of Posts and Telecommunications (bản thảo)
Mục đích và chủ đề	Bảo vệ kho tri thức RAG khỏi truy cập trái phép và rò rỉ (kể cả trích xuất bằng tiêm prompt) bằng cách mã hóa cả các đoạn văn bản và vector nhúng trước khi lưu.
Phương pháp	Xác thực người dùng và cấu trúc khóa phân cấp cho mỗi người quyền truy cập riêng vào dữ liệu riêng tư. Phương pháp A ánh xạ khóa chính sang khóa AES-CBC riêng cho từng người. Phương pháp B nối các nút dữ liệu bằng khóa sinh động và kiểm tra toàn vẹn bằng băm để an toàn hơn. Phép tính tương đồng an toàn chạy trên dữ liệu công khai, và hệ thống loại dữ liệu riêng tư của người khác trước khi trả kết quả.
Dữ liệu và đánh giá	Không có bộ dữ liệu và không có thí nghiệm trong bài. Các mục là Giới thiệu, Công trình liên quan, Phương pháp, Chứng minh bảo mật và Kết luận. Bằng chứng là các chứng minh bảo mật. Nhận định rằng hiệu năng được duy trì chỉ được nêu trong tóm tắt và kết luận, không được đo.
Kết quả chính	Chứng minh bảo mật về khả năng chống các mối đe dọa được xét. Không có kết quả định lượng.
Hạn chế	Chưa kiểm chứng trong thực tế; hướng tương lai nêu khả năng mở rộng cho tập dữ liệu lớn hơn. Mã hóa làm phát sinh việc quản lý khóa và có thể không phù hợp với tìm kiếm vector xấp xỉ nếu không có thêm công sức (**suy luận**).
Mức liên quan đến dự án	**Thấp.** Hữu ích để đối chiếu: dự án chọn lọc theo metadata với các bậc quyền, đơn giản hơn và đủ cho một tổ chức, thay vì mã hóa theo từng người. Có thể trích dẫn như một lựa chọn cho bản vận hành được gia cố, cùng với kế hoạch mã hóa mà Jeong & Lee (2025) nêu làm hướng tương lai.

4. Trợ lý doanh nghiệp và đánh giá

4.1 Mukherjee và cộng sự (2025): From Documents to Dialogue: Building KG-RAG Enhanced AI Assistants

Khía cạnh	Tóm tắt
Trích dẫn	Mukherjee, M, Kim, S, Chen, X, Luo, D, Yu, T & Mai, T 2025, Companion Proceedings of the 33rd ACM Symposium on the Foundations of Software Engineering (FSE '25), Trondheim, Na Uy, 23-27/6, ACM; arXiv:2502.15237. Carnegie Mellon University và Adobe Research. Bản đã đọc có DOI giữ chỗ, nên trích dẫn theo số arXiv.
Mục đích và chủ đề	Mô tả cách Adobe Experience Platform AI Assistant trả lời câu hỏi trên hơn 17.000 trang tài liệu nội bộ. Tìm kiếm vector thuần túy bỏ sót quan hệ giữa các khái niệm, nên nhóm tác giả xây đồ thị tri thức (Knowledge Graph, KG) từ tài liệu và dùng nó để truy xuất (KG-RAG). Đóng góp là cách xây KG chất lượng cao, ít nhiễu.
Phương pháp	Pipeline: (1) làm sạch trang (bỏ HTML, script, liên kết, thông tin tác giả) và tóm tắt mỗi trang bằng LLM; (2) phát hiện thực thể tăng dần, đưa cho LLM danh sách thực thể đã có và loại trùng lặp về ngữ nghĩa; (3) trích xuất quan hệ dạng bộ ba, mỗi bộ có độ tin cậy do LLM gán từ 0 đến 1, chỉ giữ bộ ba từ 0,6 trở lên (ngưỡng chọn bằng A/B test); (4) lưu URL nguồn với mỗi quan hệ để truy vết nguồn gốc. Lúc truy vấn, câu hỏi được nhúng, lấy bộ top-1 từ KG và thêm vào prompt gửi cho LLM (Azure OpenAI).
Dữ liệu và đánh giá	100 cặp hỏi đáp về miền 'segment', lấy từ lưu lượng thật và được chuyên gia Adobe chấm theo thang ba mức (liên quan hoàn toàn, liên quan một phần, không liên quan). Đối chứng là hệ thống sản xuất hiện tại, truy xuất tài liệu theo cosine của vector nhúng. Đánh giá dùng LLM làm giám khảo (có ví dụ trong ngữ cảnh và chuỗi suy luận; đồng thuận 85 phần trăm với người) cộng với độ tương đồng cosine của vector BERT giữa các câu trả lời.

Khía cạnh	Tóm tắt
Kết quả chính	Câu trả lời không liên quan giảm từ 52 xuống 25 (giảm 51,9 phần trăm); liên quan một phần tăng từ 31 lên 53; liên quan hoàn toàn tăng từ 17 lên 32 (tăng 88,2 phần trăm). Độ tương đồng cosine trung bình với câu trả lời tham chiếu liên quan hoàn toàn là 0,89.
Hạn chế	Bộ dữ liệu nhỏ, một miền; giám khảo LLM có thể lệch (nó có xu hướng chấm nhiều câu là liên quan một phần hơn con người); quy mô và độ trễ khi xây đồ thị; prompt và mã nguồn không công bố. Chỉ dùng top-1 (top-k là hướng tương lai). Bài không mô tả kiểm soát truy cập theo từng người dùng.
Mức liên quan đến dự án	**Trung bình.** Đây là một trợ lý tài liệu doanh nghiệp thật, nên hỗ trợ động cơ của dự án và cho một mẫu báo cáo kết quả (so sánh với mốc cơ sở, độ liên quan do chuyên gia chấm, LLM làm giám khảo kèm tỷ lệ đồng thuận). Dự án không xây đồ thị tri thức mà dùng đoạn văn bản cắt sẵn với tìm kiếm vector, nên kỹ thuật này chỉ là hướng mở rộng tương lai, không thuộc phạm vi hiện tại. Ý tưởng truy vết nguồn (lưu URL nguồn kèm mỗi sự kiện) khớp với thiết kế trả liên kết nguồn Confluence kèm mỗi câu trả lời.

4.2 Es và cộng sự (2024): RAGAs: Automated Evaluation of Retrieval Augmented Generation

Khía cạnh	Tóm tắt
Trích dẫn	Es, S, James, J, Espinosa-Anke, L & Schockaert, S 2024, Proceedings of the 18th Conference of the European Chapter of the Association for Computational Linguistics: System Demonstrations (EACL), tr. 150-158, Association for Computational Linguistics. Exploding Gradients và Cardiff University. Mã: github.com/explodinggradients/ragas.

Khía cạnh	Tóm tắt
Mục đích và chủ đề	RAG khó đánh giá vì nhiều yếu tố cùng quan trọng: văn bản truy xuất có liên quan không, mô hình có dùng nó trung thực không, và câu trả lời có tốt không. RAGAs đưa ra các chỉ số không cần đáp án tham chiếu, nên có thể ước lượng chất lượng mà không cần người viết sẵn đáp án chuẩn.
Phương pháp	Ba chỉ số, đều tính bằng cách nhắc LLM (gpt-3.5-turbo-16k). Độ trung thực (faithfulness): tách câu trả lời thành các mệnh đề rồi kiểm từng mệnh đề với ngữ cảnh truy xuất, điểm = số mệnh đề được hỗ trợ / tổng số mệnh đề. Độ liên quan của câu trả lời: sinh n câu hỏi từ câu trả lời rồi lấy trung bình cosine của vector nhúng (text-embedding-ada-002) với câu hỏi gốc. Độ liên quan của ngữ cảnh: nhờ LLM trích các câu cần thiết từ ngữ cảnh, điểm = số câu trích / tổng số câu. Đầu ra yêu cầu dạng JSON để điểm ổn định hơn. Thư viện tích hợp với LlamaIndex và LangChain.
Dữ liệu và đánh giá	WikiEval, bộ dữ liệu mới gồm 50 trang Wikipedia về các sự kiện sau đầu năm 2022, mỗi trang có một câu hỏi do ChatGPT sinh, một ngữ cảnh và các câu trả lời. Hai người gán nhãn so sánh cặp câu trả lời hoặc ngữ cảnh theo ba chiều (đồng thuận khoảng 95 phần trăm với độ trung thực và độ liên quan ngữ cảnh, khoảng 90 phần trăm với độ liên quan câu trả lời). Chỉ số được chấm bằng tỷ lệ chọn trùng với người (độ chính xác), so với hai mốc GPT Score và GPT Ranking.
Kết quả chính	Độ đồng thuận với người (độ chính xác): độ trung thực 0,95, độ liên quan câu trả lời 0,78, độ liên quan ngữ cảnh 0,70 đối với RAGAs, so với 0,72, 0,52, 0,63 của GPT Score và 0,54, 0,40, 0,52 của GPT Ranking. Độ liên quan ngữ cảnh là chiều khó nhất, đặc biệt với ngữ cảnh dài.
Hạn chế	Phụ thuộc vào LLM chấm điểm (tác giả khuyến nghị ưu tiên mô hình mở hơn API trả phí); WikiEval nhỏ và chỉ có tiếng Anh; kết quả có thể thay đổi giữa các lần chạy và phiên bản API.

Khía cạnh	Tóm tắt
Mức liên quan đến dự án	**Cao.** Bài cho dự án một cách đánh giá chất lượng câu trả lời có sẵn, rẻ, không cần viết đáp án tham chiếu cho từng trang Confluence. Độ trung thực ứng với quy tắc "chỉ trả lời từ văn bản đã truy xuất" của nhóm; độ liên quan ngữ cảnh giúp chỉnh kích thước đoạn và top-k. Lưu ý: các chỉ số chỉ được kiểm chứng trên tiếng Anh, trong khi dự án phải xử lý cả tiếng Việt, nên điểm trên câu hỏi tiếng Việt cần được kiểm tra tay; và LLM chấm điểm phải chạy cục bộ hoặc trên hạ tầng được phê duyệt nếu câu hỏi chạm tới dữ liệu nội bộ (**suy luận**). RAGAs chỉ đo chất lượng câu trả lời nên phải kết hợp với kiểm thử quyền riêng (xem Mục 3).

5. Kiến trúc và hạ tầng

5.1 Boonsri & Buranasaksee (2025): A Repository-First Framework for Democratizing Chatbot Development

Khía cạnh	Tóm tắt
Trích dẫn	Boonsri, R & Buranasaksee, U 2025, 2025 9th International Conference on Information Technology (InCIT), IEEE, tr. 775-781, doi:10.1109/INCIT66780.2025.11276047, Rajamangala University of Technology Suvarnabhumi, Thái Lan.
Mục đích và chủ đề	Nền tảng chatbot có sẵn thì dựng nhanh nhưng gây phụ thuộc nhà cung cấp; framework tự viết thì kiểm soát được nhưng loại người không làm lập trình. Bài kiểm tra liệu framework "repository-first" kết hợp trợ lý viết mã AI có giảm được thời gian và chi phí phát triển mà không làm giảm độ tin cậy và tính dễ dùng hay không.

Khía cạnh	Tóm tắt
Phương pháp	Kiến trúc sạch bốn lớp bằng C#/.NET: Presentation (ASP.NET Core API, giao diện quản trị, giám sát SignalR, kiểm chữ ký và giới hạn tốc độ), Application (CQRS với MediatR, cơ chế plug-in cho tính năng mới), Domain (trạng thái phiên, lịch sử tin nhắn, vector nhúng tùy chọn) và Infrastructure (bộ điều hợp, PostgreSQL qua EF Core với pgvector cho tìm kiếm ngữ nghĩa, Redis cho phiên và bộ nhớ đệm, truy cập LLM, Google API). Chuyên gia nghiệp vụ điền một playbook ngắn; trợ lý viết mã sinh handler, route, trình kiểm tra và test, người duyệt chấp nhận qua danh sách kiểm tra; mọi thứ giữ dưới dạng tệp Git thuần.
Dữ liệu và đánh giá	Thí nghiệm trong cá nhân (within-subjects): chín lập trình viên chuyên nghiệp, tám vi nhiệm vụ tương đương trên chatbot LINE với Google Sheets, hai điều kiện (Framework+Agent và chỉ Agent), 144 lượt chạy, giới hạn 90 phút mỗi điều kiện, đảo thứ tự. Một nghiên cứu System Usability Scale (SUS) riêng với 50 người dùng (quản lý, hỗ trợ dự án, kinh doanh). Trợ lý chạy trên mô hình cục bộ (ModelHarbor với một mô hình Qwen3), dùng Qdrant để lập chỉ mục mã nguồn.
Kết quả chính	Framework+Agent nhanh hơn và rẻ hơn: tỷ số thời gian (chỉ Agent / Framework) khoảng 2,4 và tỷ số chi phí khoảng 1,9, số lần con người phải can thiệp ít hơn 1,9 lần, tỷ lệ lỗi tương đương. Chất lượng: độ chính xác QA chuẩn hóa 0,93. SUS trung bình 70,6 (trên mốc thông dụng 68). Sáu trong tám nhiệm vụ nghiêng về framework; hai nhiệm vụ đơn giản nhất nghiêng về chỉ Agent.
Hạn chế	Chỉ tám nhiệm vụ ghép cặp nên nghiên cứu thiếu sức mạnh thống kê (tác giả tự nêu); một bộ công nghệ; người tham gia là lập trình viên chuyên nghiệp; không dùng dữ liệu thật. Các con số trong bài không hoàn toàn nhất quán (ví dụ tỷ số thời gian là 2,29 ở tóm tắt, 2,44 ở Bảng I và 2,48 trong văn bản, và khoảng tin cậy của SUS khác nhau giữa các mục), nên hãy trích giá trị tóm tắt hoặc số làm tròn, không trích quá chi tiết phần thập phân.

Khía cạnh	Tóm tắt
Mức liên quan đến dự án	**Trung bình.** Kiến trúc phân lớp (trình bày, ứng dụng, miền, hạ tầng) gần với bốn lớp của nhóm, và bài cũng độc lập chọn PostgreSQL với pgvector cùng bộ nhớ đệm, hỗ trợ quyết định lưu trữ của nhóm. Bài dùng bảng câu hỏi SUS, nhóm có thể tái sử dụng cho bài kiểm thử tính dễ dùng với khách hàng. Bài nói về xây chatbot bằng trợ lý viết mã, không phải truy xuất hay bảo mật, nên chỉ hỗ trợ lựa chọn kiến trúc và quy trình, không hỗ trợ vấn đề nghiên cứu.

5.2 Mohammed & Aref (n.d.): Chatbot System Architecture

Khía cạnh	Tóm tắt
Trích dẫn	Mohammed, M & Aref, MM n.d., 'Chatbot System Architecture', Faculty of Computer and Information Sciences, Ain Shams University, Cairo. **Bản đã đọc không ghi năm và nơi công bố; cần xác nhận trước khi trích dẫn.**
Mục đích và chủ đề	Tổng quan mô tả kiến trúc chuẩn của một tác nhân hội thoại, giải thích từng thành phần.
Phương pháp	Mô tả dựa trên tài liệu (không có thí nghiệm). Ba thành phần cốt lõi: Natural Language Understanding (phát hiện chủ đề, phân tích ý định, liên kết thực thể), Dialogue Manager (dựa luật, dựa tri thức, truy xuất thông tin trực tuyến, sinh câu trả lời bằng mạng nơ-ron, theo dõi ngữ cảnh) và Natural Language Generator (bộ lọc nội dung, xếp hạng mức hấp dẫn, đầu ra văn bản hoặc giọng nói). Một nghiên cứu tình huống về bot Messenger của hãng hàng không KLM.
Dữ liệu và đánh giá	Không có. Nghiên cứu tình huống KLM nêu, dựa trên khảo sát khách hàng, mức tương tác qua Messenger tăng (ghi là 40 phần trăm) và khoảng 15 phần trăm thành công đặt vé trực tuyến được cho là nhờ bot, không nêu phương pháp hay mốc so sánh.

Khía cạnh	Tóm tắt
Kết quả chính	Không có kết quả đo lường. Kết luận: Dialogue Manager là thành phần quan trọng nhất vì các bộ phận của nó có thể được cải tiến hoặc thay thế.
Hạn chế	Quan điểm chatbot trước thời LLM (luật, ý định, sinh bằng mạng nơ-ron); không có retrieval-augmented generation; không có bảo mật hay kiểm soát truy cập; văn phong không chặt chẽ và nguồn số liệu nghiên cứu tình huống không rõ.
Mức liên quan đến dự án	**Thấp.** Chỉ hữu ích như một tài liệu cấp giáo trình ngắn về cách chatbot thường được chia thành hiểu, quản lý hội thoại và sinh. Trong hệ thống của nhóm, bộ định tuyến và LLM thay thế phần lớn các thành phần này, nên bài giúp giải thích thuật ngữ cho khách hàng phi kỹ thuật nhưng không nên dùng làm bằng chứng cho lựa chọn thiết kế.

5.3 Malkov & Yashunin (2020): Efficient and Robust Approximate Nearest Neighbor Search Using HNSW Graphs

Khía cạnh	Tóm tắt
Trích dẫn	Malkov, YA & Yashunin, DA 2020, IEEE Transactions on Pattern Analysis and Machine Intelligence (bản đã đọc còn đầu đề mẫu; **cần xác nhận tập và số trang trước khi trích dẫn**; arXiv:1603.09320).
Mục đích và chủ đề	Tìm nhanh K vector gần nhất với truy vấn trong tập lớn (tìm láng giềng gần nhất xấp xỉ), là thao tác cốt lõi của tìm kiếm vector trong RAG.
Phương pháp	Hierarchical Navigable Small World (HNSW): đồ thị nhiều tầng. Mỗi phần tử được gán tầng tối đa ngẫu nhiên với xác suất giảm theo hàm mũ, nên tầng trên thưa và có liên kết dài, tầng dưới dày. Tìm kiếm bắt đầu ở tầng trên cùng và đi xuống theo cách tham lam; một heuristic chọn láng giềng cải thiện recall trên dữ liệu tập cụm. Tham số chính: M (số liên kết mỗi phần tử), efConstruction (danh sách ứng viên khi xây) và ef (danh sách ứng viên khi tìm). Chi phí tìm kiếm tăng xấp xỉ theo logarit của kích thước dữ liệu.

Khía cạnh	Tóm tắt
Dữ liệu và đánh giá	Cài đặt bằng C++ trong nmslib. So sánh với NSW cơ sở, FLANN, Annoy, VP-tree, FALCONN và các phương pháp khác trên bộ vector của ann-benchmarks (SIFT 1M, GloVe 1,2M, CoPhIR 2M, DEEP 1M, MNIST 60k và vector ngẫu nhiên tới 30M), trên các bộ phi metric (Wiki-sparse, Wiki-8/128, ImageNet signatures, DNA) và so với phương pháp lượng tử hóa tích (product quantisation) trên tập SIFT 200M.
Kết quả chính	HNSW vượt các phương pháp chỉ dùng vector mã nguồn mở khác trong các thử nghiệm đã báo cáo, dùng ít phép tính khoảng cách hơn hẳn NSW và tăng quy mô gần logarit theo kích thước dữ liệu.
Hạn chế	Tác giả liệt kê là việc tương lai: hỗ trợ cập nhật và xóa phần tử; cũng nêu rằng khác NSW cơ sở, tìm kiếm phân tán không đơn giản. Bộ nhớ dùng nhiều hơn các phương pháp nén (lượng tử hóa).
Mức liên quan đến dự án	**Trung bình.** Chỉ mục HNSW của pgvector cài đặt thuật toán này, nên bài là trích dẫn đúng cho lý do tìm kiếm của nhóm vẫn nhanh khi Confluence lớn dần, và cho các tham số M và ef sẽ chỉnh. Điểm về cập nhật và xóa liên quan đến một vấn đề đã biết trong thiết kế (**suy luận**): khi trang Confluence được sửa hoặc xóa, các đoạn cũ phải được thay hoặc gỡ, điều mà thuật toán gốc không giải quyết; đây là lý do đề xuất tác vụ dọn dẹp định kỳ.

6. Tổng hợp, khoảng trống và điểm cho buổi trình bày

6.1 Mười bài cho thấy điều gì khi đặt cạnh nhau

1. **Kiểm soát truy cập là khoảng trống của phần lớn tài liệu.** Chỉ Jeong & Lee (2025) và Bhatt và cộng sự (2025) bàn về ai được xem gì trong hệ thống RAG, còn Zhou và cộng sự (2025) đưa ra thiết kế mã hóa nhưng không có thí nghiệm. Lewis và cộng sự (2020) cùng Gao và cộng sự (2024) không đề cập kiểm soát truy cập. Điều này hỗ trợ nhận định rằng truy xuất nhận biết quyền là yêu cầu làm nên sự khác biệt của dự án.

2. **Thiết kế của nhóm khác công trình gần nhất ở hai điểm.** Jeong & Lee lấy top-k trước rồi kiểm từng tài liệu với IAM của chủ sở hữu, nên chất lượng câu trả lời giảm khi người dùng chỉ được đọc ít tài liệu. Dự án đặt bộ lọc quyền ngay trong truy vấn cơ sở dữ liệu, nên top-k chỉ được chọn từ văn bản được phép. Cái giá (**suy luận**) là quyền được sao chép lúc nạp dữ liệu và có thể lỗi thời cho đến lần đồng bộ kế tiếp, trong khi Jeong & Lee kiểm tra theo thời gian thực. Sự đánh đổi này cần nói rõ.
3. **Slack đặt ra vấn đề người tham gia.** Bhatt và cộng sự cho rằng nội dung phải được phép với mọi người tham gia. Một luồng hay kênh Slack đọc được bởi mọi thành viên, nên câu trả lời của bot không nên vượt quá những gì khán giả được xem (**suy luận**). Điều này chưa được quyết định trong thiết kế và là một câu hỏi mở tốt để nêu.
4. **Đánh giá gồm hai phần tách biệt.** Chất lượng câu trả lời có thể đo bằng RAGAs (độ trung thực, độ liên quan câu trả lời, độ liên quan ngữ cảnh) và từ vựng của Gao và cộng sự; đúng sai về quyền cần bộ kiểm thử riêng, ví dụ các chỉ số permission coverage, exact match và F1 của Jeong & Lee, cùng kiểm thử negative rejection. RAGAs chỉ được kiểm chứng trên tiếng Anh nên kết quả tiếng Việt cần kiểm tay.
5. **Lựa chọn hạ tầng được hỗ trợ nhưng chưa được chứng minh cho trường hợp của nhóm.** Boonsri & Buranasaksee (2025) dùng PostgreSQL với pgvector và bộ nhớ đệm trong kiến trúc phân lớp, và Malkov & Yashunin (2020) là thuật toán đằng sau chỉ mục HNSW của pgvector. Bài HNSW gốc liệt kê cập nhật và xóa là việc tương lai, liên quan đến nhu cầu thay hoặc gỡ đoạn khi trang Confluence đổi.
6. **Chất lượng nguồn khác nhau.** Đã qua phản biện hoặc có nơi công bố: Lewis và cộng sự (NeurIPS), Jeong & Lee (IEEE Access), Es và cộng sự (EACL), Boonsri & Buranasaksee (IEEE InCIT), Mukherjee và cộng sự (ACM FSE Companion) và Malkov & Yashunin (IEEE TPAMI). Bản thảo: Gao và cộng sự, Bhatt và cộng sự, Zhou và cộng sự (arXiv). Mohammed & Aref không có nơi công bố trong bản đã đọc. Khi trích các bài arXiv nên nói rõ đây là bản thảo (preprint).

6.2 Khoảng trống mà dự án có thể nêu

- Truy xuất nhận biết quyền cho bối cảnh Slack và Confluence, với bộ lọc đặt trong truy vấn vector chứ không phải sau khi truy xuất.
- Trợ lý tri thức doanh nghiệp song ngữ (tiếng Anh và tiếng Việt); không bài nào trong mười bài đánh giá tiếng Việt.
- Đánh giá báo cáo đồng thời chất lượng câu trả lời và đúng sai về quyền.

6.3 Giới hạn cần nói thẳng

- Zhou và cộng sự không có thí nghiệm, Bhatt và cộng sự không có kết quả đo lường; cả hai hỗ trợ lập luận chứ không phải một khẳng định định lượng.

- Thí nghiệm của Jeong & Lee dùng HotpotQA chứ không phải dữ liệu doanh nghiệp, và Mukherjee và cộng sự dùng 100 câu hỏi trong một miền, nên không được trình bày các con số đó là kết quả kỳ vọng của hệ thống của nhóm.
- Các mục đánh dấu suy luận là cách đọc của nhóm, nên nêu rõ điều này khi trình bày.

6.4 Thứ tự gợi ý và thông điệp một dòng cho từng bài

1. Lewis và cộng sự: đây là mẫu mà nhóm triển khai (truy xuất rồi sinh, tri thức có thể cập nhật).
2. Gao và cộng sự: đây là cách mô tả và đánh giá phiên bản RAG của nhóm.
3. Jeong & Lee: công trình gần nhất về quyền, và nơi thiết kế của nhóm khác.
4. Bhatt và cộng sự: vì sao quyền phải được thực thi bên ngoài mô hình, và câu hỏi người tham gia trên Slack.
5. Es và cộng sự (RAGAs): cách nhóm sẽ đo chất lượng câu trả lời.
6. Mukherjee và cộng sự, Boonsri & Buranasaksee: ví dụ về trợ lý doanh nghiệp và kiến trúc phân lớp.
7. Malkov & Yashunin: vì sao tìm kiếm vector vẫn nhanh; lưu ý về cập nhật và xóa.
8. Zhou và cộng sự, Mohammed & Aref: chỉ để đối chiếu và giải thích thuật ngữ.

6.5 Câu hỏi một giảng viên khắt khe có thể hỏi

- Vì sao lọc trước khi truy xuất chứ không lọc sau? (Trả lời: tránh mất chất lượng khi độ phủ quyền thấp; đánh đổi là quyền có thể cũ giữa các lần đồng bộ.)
- Làm sao biết câu trả lời đúng và được phép? (Trả lời: RAGAs cho chất lượng, kiểm thử quyền riêng cho truy cập.)
- Ai xem được câu trả lời của bot trong kênh? (Trả lời: quyết định còn mở; Bhatt và cộng sự gợi ý giới hạn đến mức mọi người tham gia đều được xem.)
- Vì sao tin các bản thảo arXiv? (Trả lời: dùng cho lập luận và từ vựng; các khẳng định quan trọng dựa vào các bài đã công bố.)
- Có chạy được bằng tiếng Việt không? (Trả lời: các bài chưa kiểm chứng; nhóm tự kiểm thử.)

7. Tài liệu tham khảo

Bhatt, SS et al. 2025, *Enterprise AI must enforce participant-aware access control*, arXiv:2509.14608, preprint.

Boonsri, R & Buranasaksee, U 2025, 'A repository-first framework for democratizing chatbot development', *2025 9th International Conference on Information Technology (InCIT)*, IEEE, pp. 775-781, doi:10.1109/INCIT66780.2025.11276047.

Es, S, James, J, Espinosa-Anke, L & Schockaert, S 2024, 'RAGAs: automated evaluation of retrieval augmented generation', *Proceedings of the 18th Conference of the European Chapter of the Association for Computational Linguistics: System Demonstrations*, Association for Computational Linguistics, pp. 150-158.

Gao, Y et al. 2024, *Retrieval-augmented generation for large language models: a survey*, arXiv:2312.10997, preprint.

Jeong, J & Lee, S-G 2025, 'Permission-aware retrieval-augmented generation', *IEEE Access*, vol. 13, pp. 192819-192835, doi:10.1109/ACCESS.2025.3628960.

Lewis, P et al. 2020, 'Retrieval-augmented generation for knowledge-intensive NLP tasks', *Advances in Neural Information Processing Systems*, vol. 33.

Malkov, YA & Yashunin, DA 2020, 'Efficient and robust approximate nearest neighbor search using hierarchical navigable small world graphs', *IEEE Transactions on Pattern Analysis and Machine Intelligence*, arXiv:1603.09320 (confirm volume and pages before citing).

Mohammed, M & Aref, MM n.d., *Chatbot system architecture*, Ain Shams University, Cairo (confirm year and venue before citing).

Mukherjee, M, Kim, S, Chen, X, Luo, D, Yu, T & Mai, T 2025, 'From documents to dialogue: building KG-RAG enhanced AI assistants', *Companion Proceedings of the 33rd ACM Symposium on the Foundations of Software Engineering (FSE '25)*, ACM, arXiv:2502.15237.

Zhou, P, Feng, Y & Yang, Z 2025, *Privacy-aware RAG: secure and isolated knowledge retrieval*, arXiv:2503.15548, preprint.